

Во время посещения сайта вы соглашаетесь с использованием файлов [cookie](#)

Хорошо



Михаил Шардин ★

личный блог




17 октября 2025, 06:35

+ Подписаться

Как я погружаюсь в ML и понимаю, что всё начинается с данных

Экспериментирую с ML. Несколько недель ковыряюсь в данных и всё больше понимаю — алгоритмы это не главное. Главная боль — подготовка данных.

Баланс классов по временным периодам




Уже несколько недель разбираюсь с машинным обучением. Не ради статьи на Смартлабе — захотелось понять, как это устроено изнутри. И чем глубже погружаюсь, тем больше понимаю: вся «магия» моделей начинается задолго до самого обучения.

Собрать данные — не проблема. Подготовить их — проблема. И особенно сложно — сбалансировать классы.

Когда модель учится отличать категории, она должна видеть их примерно в равных долях. Если один класс встречается гораздо чаще других, модель быстро «разучивается думать» и начинает просто угадывать самый частый вариант. В итоге вроде бы всё обучилось, но результат — в мусорку.

На практике это выглядит так:

- один класс (нейтральный) встречается чуть ли не в половине всех примеров,



КОНФЕРЕНЦИЯ
СМАРТЛАБ
20 ИЮНЯ


Забрать инвестици на 2026

Введите текст комментария

Во время посещения сайта вы соглашаетесь с использованием файлов [cookie](#)

После долгих экспериментов и отбраковки однотипных записей я получил такую картину:

Баланс классов по временным периодам



Выглядит вроде бы прилично, но за этими цифрами — десятки вариантов фильтрации, пересемплирования и чистки.

Главная проблема — нейтральные примеры. Их очень много, и именно они чаще всего «смазывают» сигналы в данных.

Удалить слишком много — модель потеряет способность видеть естественные переходные состояния.

Удалить слишком мало — она начнёт всё считать нейтральным.

Это [в продолжение темы](#).

Поэтому подбор баланса — это не механическая операция, а прямо сложно.

Ведь машинное обучение — это не про «нажал кнопку и получил результат» как в ChatGPT. Это скорее про методичное, почти исследовательское выравнивание весов, классов и смыслов.

Если кто-то тоже бьётся с дисбалансом классов — делитесь опытом в комментариях.

Особенно интересны реальные кейсы, где удалось найти золотую середину между балансом и сохранением репрезентативности данных.

Автор:

Михаил Шардин

[Моя онлайн-визитка](#)

[Telegram «Умный Дом Инвестора»](#)

17 октября 2025



КОНФЕРЕНЦИЯ
СМАРТЛАБ
20 ИЮНЯ

Забрать инвести идеи на 2026

Во время посещения сайта вы соглашаетесь с использованием файлов [cookie](#)

ML

торговые роботы

искусственный интеллект

ИИ

5.7K  2 24 13**Михаил Шар...** Пермь 525  5 912 с 23 января 2019[+ Подписаться](#)

24 КОММЕНТАРИЯ

Сначала старые **Михаил**

17 октября 2025, 07:00

Никак, потому что не имею дело с классами, а предсказываю распределение доходности

  +1 **Ho_Chu**

17 октября 2025, 07:20

рискнул бы не согласиться с тезисом о неважности алгоритмов

взять хотя бы вчерашний день

из-за произошедших событий придется заново обучать некоторые алгоритмы, хотя другие демонстрируют поразительную стойкость к такого рода явлениям, при этом все используют почти один и тот же входной набор данных

но, кажется мне, что даже новое переобучение не поможет... а вот почему не поможет, — это надо сильно подумать

  +1 **Максим Павлов**

17 октября 2025, 09:54

Смотря какой алгоритм используешь. Но почти в любом алгоритме машинного обучения есть параметр по типу «scale_pos_weight», который делает больше веса в обучении на примеры

КОНФЕРЕНЦИЯ
СМАРТЛАБ
20 ИЮНЯ[Забрать инвестиции на 2026](#)

Во время посещения сайта вы соглашаетесь с использованием файлов [cookie](#)

— Показать 4 ответа



Ещё 7 комментариев

Напишите комментарий...



ОТПРАВИТЬ


Читайте на SMART-LAB:

АКРА подтвердило кредитный рейтинг ДельтаЛизинг на уровне AA-(RU)

Аналитическое кредитное рейтинговое агентство (АКРА) подтвердило кредитный рейтинг ДельтаЛизинг (входит в группу «Инсайт Лизинг») на уровне AA-(RU), изменив прогноз со...

 ДельтаЛизинг

04:07




Давление на рубль нарастает

Опять видим подъем однодневной ставки размещения свободных юаней на МосБирже. Она отталкивается всё ещё от околонулевы...



Иволга Капитал

06:34




Сравниваем облигации гигантов ритейла

Российский продуктовый ритейл остается одним из самых понятных защитных сегментов для долгового рынка. Спрос здес...



Финам Брокер


16.06.2026



КОНФЕРЕНЦИЯ
SMARTLAB
20 ИЮНЯ

Забрать инвестицдеи на 2026

Во время посещения сайта вы соглашаетесь с использованием файлов [cookie](#)



14 недель подряд доминируют продажи на российском рынке.

Три основных вопроса я ставил сегодня на еженедельном...



Mozgovik

15.06.2026

Установите приложение Смартлаба:



RuStore



AppGallery



App Store



[О смартлабе](#)

[Реклама](#)

[Полная версия](#)

Источник: [ПАО Московская Биржа](#)



КОНФЕРЕНЦИЯ
СМАРТЛАБ
20 ИЮНЯ

Забрать инвестицдеи на 2026