РЕКЛАМА
SourceCraft
Разобрать сложную тему за пару кликов
Краткое содержание, код, комментарии и практика — с обновленной фичей SourceCraft
Посмотреть, как →



empenoso
13 янв в 05:22

Объяснить с

ML на Мосбирже — почему мой грааль не работает?

Средний 7 мин 12K

Open source*, Python*, Финансы в IT, Машинное обучение*, Искусственный интеллект

Кейс Сезон ИИ в разработке

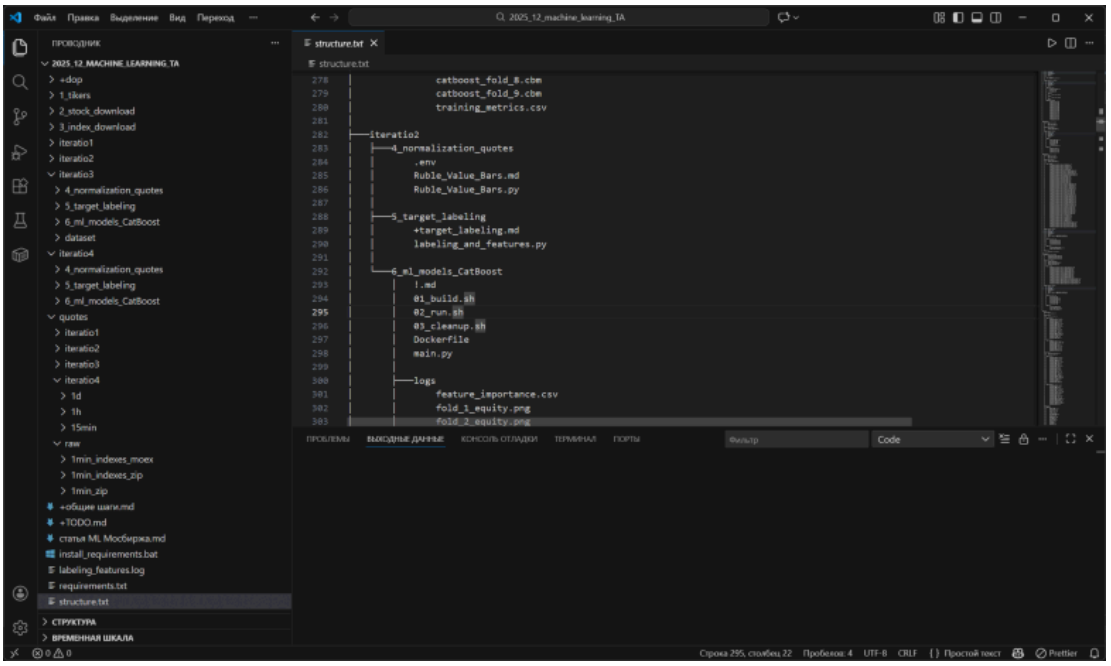
Время после нового года решил провести с пользой и окунуться в машинное обучение. Заняться Machine Learning — и посмотреть получится что-то или нет с российским рынком акций на Московской бирже.

Моей целью было построить такую систему, которая будет учиться на истории и в перспективе торговать лучше чем случайное блуждание 50/50. Но из-за комиссий и спреда подобные блуждания изначально отрицательны — чтобы выйти в плюс надо как минимум покрывать комиссии.

Если говорить о результатах очень кратко, то технически всё работает, но вот финансовый результат на грани безубыточности.

Если Вы только интересуетесь этой темой Вы можете посмотреть какие-то шаги в моей статье, а если Вы уже опытный разработчик подобных систем, то можете подсказать что-нибудь в комментариях.

Причём вся эта работа выглядит совершенно не так как показывается в фильмах про уолл-стрит: фактически это написание скриптов и монотонный запуск и всё происходит полностью локально на компьютере.



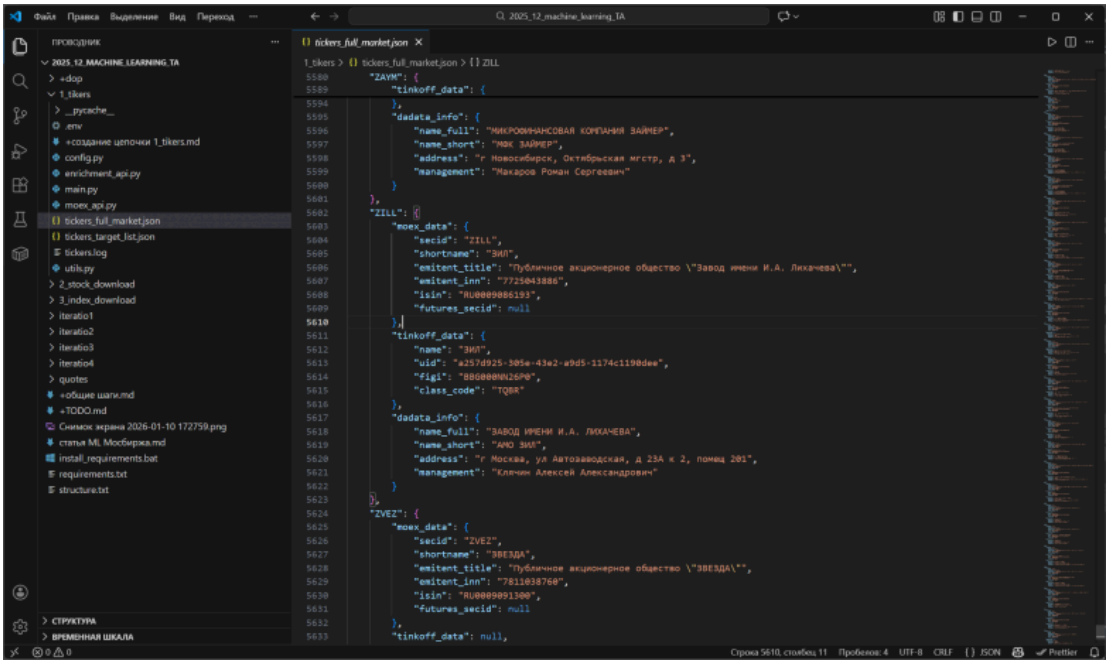
Скриншот VS Code открытым деревом проекта

Охота за данными

Вообще данные очень важны. Иначе получается что мусор на входе просто перетекает в мусор на выходе.

Для отбора бумаг я руководствовался следующей логикой: сначала ищу общий список всех акций, торгуемых на Московской бирже и делаю выборку — в неё входят только те, у которых есть фьючерсы. Дальше оставляю только тикеры акций, которые имеют фьючерсы.

Потом беру два API — одно от брокера, а второе API, предоставляющее информацию по всем юридическим лицам России — это API DaData. У каждой акции ведь есть ИНН компании. Используя оба этих API — оба бесплатных кстати — обогащаю каждую запись дополнительными сведениями.



Фрагмент файла tickers_full_market.json с общим список тикеров

После этого скачиваю котировки акций с Московской биржи. И загружаю три индекса: IMOEX, IMOEX2, RTSI, RGBI.

Для этого скачиваю минутки — они готовые и сразу в архивах через API брокера — можно очень быстро скачать полностью все бумаги.

С индексами сложнее. Брокерский API не отдавал историю по IMOEX и RGBI, видимо, из-за ограничений лицензии биржи (привет, MOEX AlgoPack). Пришлось писать парсер для прямого API Московской биржи (ISS MOEX) — скорость гораздо медленнее, но я скачиваю тоже минутки. Скачать все доступные минутки с IMOEX, IMOEX2, RTSI, RGBI занимает около 20 минут.

Котировки индекса

Работа со временем

Я начал работу с того, что выделил три интересующих меня таймфрейма. 15 минут, 1 час и 1 день, основной 1 час.

Написал скрипт который преобразует архивы с минутками от API брокера в файлы с котировками нужных таймфреймов.

Итерация 1,3,4: временные бары (обычные)

Сначала я просто агрегировал минутки в 15 минут, 1 час и 1 день через скрипт, но рынок неравномерен. Возможно для ML-модели временные свечи могут быть очень шумные, так как содержат разное количество информации.

Скрипт normalization_quotes_stock.py который читает 1-минутные архивы (ZIP) из quotes/1min_zip и агрегирует данные в 15min, 1h, 1d

Итерация 2: свечи рублевого объема

Потом я временно перешёл к событийным барам. Новая свеча формируется не по времени, а когда проходит фиксированный объем в рублях, например, 50 млн руб., но для разных акций этот порог разный, потому что рассчитывается динамически. Разделил их по условным классам:

- A: порог выше.
- B: порог ниже.
- C: отбрасываются.

Скрипт который создаёт из минутных котировок свечи рублевого объема и классифицирует бумаги по классам

Учитель для робота. Разметка

Как объяснить машине, что такое «хорошая сделка»? Рынок может продолжать рост, но перед этим выбить по стопу.

Книга Маркос Лопез де Прадо «Машинное обучение: алгоритмы для бизнеса»

Книга «Машинное обучение: алгоритмы для бизнеса»

Привет, Хаброжители! Маркос Лопез де Прадо делится тем, что обычно скрывают, — самыми прибыльными ал...

habr.com



Для установки цели я использовал тройной барьер по де Прадо:

- Верхний барьер (Take Profit): Цена + N×ATR
- Нижний барьер (Stop Loss): Цена - M×ATR
- Вертикальный барьер (Time Limit): Если прошло 100 баров, а цена никуда не пришла — выходим.

Скрипт расставляет метки:

Метка 1: сработал Take Profit.

Метка 0: вышло время, выход в ноль (минус комиссия).

Метка -1: сработал Stop Loss, потеря денег.

Фрагмент в Visual Studio Code

Глаза модели: инженерия признаков

Я использовал CatBoost (Categorical Boosting) это библиотека машинного обучения с открытым исходным кодом от «Яндекса», основанная на градиентном бустинге над деревьями решений. Я не подаю сырые цены (OHLCV: Open (цена открытия), High (максимальная цена), Low (минимальная цена), Close (цена закрытия) и Volume (объем торгов)), так как они не стационарны, потому что цена 100 ₽ в 2010 и 100 ₽ в 2024 — это разные сущности, а использую только относительные величины.

Я старался подавать именно Log Returns (логарифмические доходности), потому что Log returns аддитивны и симметричны: падение на 50% и рост на 100% имеют одинаковый масштаб в логарифмах.

Сами признаки, в разных итерациях по разному было:

- Качество импульса: не просто «цена выросла», а как она выросла. Использую автокорреляцию и эффективность тренда.
- Микроструктура: что происходило внутри этой свечи рублевого объема? Какая концентрация объема?

- Межрыночные связи: как актив ведет себя относительно индекса Мосбиржи и индекса гособлигаций RGBI.
- Классика: RSI (нормализованный через Z-score), расстояния до скользящих средних.

Файл для генерации признаков и разметки

Моделирование

Для того чтобы заниматься ML все инструменты у меня были: компьютер 32 Гб оперативки с видеокартой GPU 16 Гб, Python как основной язык, Docker чтобы не зависеть от капризов драйверов, Numba для ускорения расчётов, Linux для администрирования Docker контейнеров.

Нейросети как консультант: как я нашел и заказал ПК без подсветки для локальной работ…

Внимание, знатоки! Если вы профессионально разбираетесь в компьютерном железе, тонкостях сборки или ...

habr.com



Для моей задачи как будто даже избыточная конфигурация — потому что все расчёты протекают очень быстро.

Dockerfile

Делаю это из под Ubuntu, хотя всю разработку веду из-под Windows.

01_build.sh

Ещё использую измененную версию пошагового тестирования (Walk-Forward Optimization), которая используется в трейдинге для поиска и проверки торговых стратегий, но добавляя «очистку» (purging) данных: она избегает перекрытия обучающих и тестовых периодов, чтобы предотвратить подгонку стратегии под шум истории, делая результаты более реалистичными и устойчивыми к будущим изменениям рынка.

Результаты и боль

При просмотре результатов магия машинного обучения быстро испаряется.

Я учитываю комиссии:

```
COMMISSION_PCT = 0.04 / 100  # комиссия брокера
SLIPPAGE_PCT   = 0.02 / 100  # проскальзывание
```

Объяснить с SourceCraft

Каждая сделка автоматически теряет 0,06% или 0,12% на круг для акций. Кажется мелочью, но при сотнях сделок именно эти десятые доли процента превращают модель в убыточную. Модели нужно предсказывать движения >0,3-0,5%, чтобы быть в плюсе.

По качеству прогнозов мой ML стабильно показывает AUC 0,54–0,55. Формально это лучше случайного угадывания (0.50), но до Грааля тут очень далеко. Почему? Даже небольшая ошибка в вероятностях, умноженная на комиссии и шум, быстро съедает весь перевес.

Чтобы понимать, что именно я меряю, важно разобраться в трёх ключевых метриках.

AUC (Area Under the Curve) — это мера того, насколько хорошо модель умеет отличать «хорошие» сделки от «плохих». Если AUC = 0.5, модель — это монетка. Если 0.55 — она угадывает чуть чаще, чем случайность. В вакууме это звучит неплохо, но в трейдинге такого преимущества часто недостаточно, чтобы перекрыть издержки.

Fold — это один из прогонов в Walk-Forward Optimization. История рынка режется на последовательные отрезки: на одном модель учится, на следующем тестируется. Каждый такой отрезок — отдельный fold. Это имитация реальности: мы всегда торгуем на будущем, которого модель «не видела». Поэтому один fold может быть прибыльным, а следующий — убыточным, просто потому что режим рынка поменялся.

Тесты

Precision (точность) — это ответ на вопрос: «если модель сказала „покупай“, как часто она оказывается права?». Это критично для торговли, потому что даже модель с неплохим AUC может генерировать кучу ложных сигналов, которые будут съедать депозит комиссиями и стоп-лоссами.

И вот здесь появляется самая болезненная часть. На одном из фолдов я получаю красивую Equity Curve, где капитал растёт.

График fold_2_best_equity

На другом — та же самая модель превращает счёт в “пилу”: заработали на тренде, потом долго и мучительно всё отдали на боковике.

График fold_3_best_equity

Когда я писал этот текст мне в голову пришло, а что если модель обучать на максимизацию финансового показателя, такого как Коэффициент Шарпа?

Заключение: вопросы к залу

Я проделал некоторую работу, но результаты пока выглядят не особо приятными.

Мои гипотезы:

1. Ошибка в методологии?
2. Мало данных?
3. Предсказывать не направление, а волатильность?

4. Перейти на более высокие таймфреймы (4H, 1D), где комиссия съедает меньшую долю движения?
5. Нужно использовать данные из стакана (Order Book)? С получением истории стакана для частного лица большие проблемы. Бесплатно доступен лишь очень ограниченный набор инструментов.
6. CatBoost слишком прост, нужны трансформеры?

Я занимаюсь Machine Learning (ML), когда система учится на таблицах. Но есть ведь ещё Deep learning (глубокое обучение) когда идёт анализ больших объёмов данных и выявления сложных закономерностей автономно. Но боюсь для моей задачи слишком мало данных. Наверное только на истории стаканов OrderBook будет работать.

Google Maps для биржевого стакана: пишем визуализатор данных Московской биржи на P…

Обычный трейдер смотрит на свечной график, но свеча — это уже тень прошлого, постфактум. Между тем н...

habr.com



Приглашаю в комментарии: кто реально запускал Machine Learning на Мосбирже в плюс? Или просто опытных людей. Где я свернул не туда?

Не сдерживайте себя — напишите комментарий — буду рад любой критике в комментариях.

Автор: Михаил Шардин
🔗 Моя онлайн-визитка
📢 Канал «Умный Дом Инвестора» в TG или MAX

13 января 2026 г.

Теги: machine learning, deep learning, московская биржа, мосбиржа, auc, Сезон ИИ в разработке, алгоритмическая торговля

Хабы: Open source, Python, Финансы в IT, Машинное обучение, Искусственный интеллект

Редакторский дайджест
Присылаем лучшие статьи раз в месяц

Электропочта

Подписаться

Дайджест может содержать маркетинговые материалы. Подписываясь, вы соглашаетесь на их получение и обработку данных согласно Политике конфиденциальности



8K+ Охват за 30 дней
264 Карма

Михаил Шардин @empenoso
Автоматизация / Data & ML / Финансы / Smart Home

Подписаться

Сайт GitHub

Комментарии 33

ЕЖЕДНЕВНЫЙ ХАБР | 14 ОКТ 2026

48K



Oracle показала, что у технологической ИИ-революции могут закончиться деньги

Искусственный интеллект обещал изменить мировую экономику. Но пока компании рассказывают о революции производительности, инвесторы начинают задавать значительно более приземлённый вопрос:
Кто заплатит за сотни миллиардов долларов, уже потраченных на эту революцию? История Oracle…

8 неочевидных вариантов использования Claude Opus 5.5

HTML и CSS из прошлого, которые до сих пор актуальны

Керамика, чай и русский врач из Токио: как я путешествовал по Японии

Ещё

0

Публикации

ЛУЧШИЕ ЗА СУТКИ ПОХОЖИЕ

ValdikSS
9 часов назад

Как сцена взлома принтеров изобрела собственный DRM

12 мин 9.3K

Ретроспектива

+51 21 8

shiru8bit
22 часа назад

Как Марио ZX Spectrum покорял

Простой 22 мин 9.6K

Ретроспектива

+48 12 4

vital_pavlenko
12 часов назад

Конец привычного уютного айти. Что делать дальше

3 мин 12K

+31 21 83

dalerank
17 часов назад

Не делайте NPC умнее игрока

18 мин 12K

Мнение

+25 25 16

Firemoon
3 часа назад

Будни администратора Minecraft-сервера: пора обновляться

10 мин 3.4K

+22 2 0

alexsyntx
17 часов назад

8 неочевидных вариантов использования Claude Opus 5.5

Простой 5 мин 56K

Обзор

+19 40 20

opium
18 часов назад

Я не хочу читать то, чего вы не писали

10 мин 9.3K

Мнение Перевод

+19 14 8

oldadmin
4 часа назад

Самохостинг 10 ТБ на ноутбуке, свой сервер вместо облака, личные сайты и сисопки

Средний 5 мин 4.2K

Обзор

+18 18 2

verimash
19 часов назад

Яндекс.Диск — скачиваем фото и видео из хранилища «безлимита» с попыткой восстановить повреждённые

Простой 6 мин 14K

Туториал

+18 26 73

avp_kirin
20 часов назад

Керамика, чай и русский врач из Токио: как я путешествовал по Японии

Простой 10 мин 49K

Репортаж

+18 20 7

Роботы за $1000, телехирургия и AI: что я увидел на стартап-саммите

Турбо

Показать еще

ИСТОРИИ

Мы знаем, кто определит будущее разработки

Тебе бы в ИБ, а ты всё на драккаре плаваешь

Made in AI

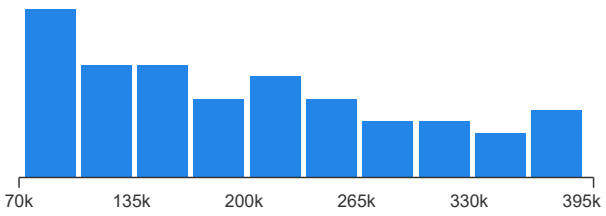
Интернет всему голова

Все ответы у них

СРЕДНЯЯ ЗАРПЛАТА В IT

205 808 ₽/мес.

— средняя зарплата во всех IT-специализациях по данным из 28 372 анкет, за 2-ое пол. 2026 года. Проверьте «в рынке» ли ваша зарплата или нет!



Проверить свою зарплату

МИНУТОЧКУ ВНИМАНИЯ



Не поддаемся осенней хтони, ходим на ивенты из Календаря



На вашем производстве уже есть роботы? Напишите об этом кейс



Два дня внутри стартап-экосистемы

БЛИЖАЙШИЕ СОБЫТИЯ

21 сентября – 30 октября

Исследование Хабра и FRC: Контент, которому (не) верят

Онлайн

Другое

Больше событий в календаре

3

В

Р

В

Хабр

Настройка языка

Техническая поддержка

© 2006–2026, Habr

На информационном ресурсе применяются рекомендательные технологии